

Conclusão do trabalho de classificação, otimização e integração com LLMs

O projeto utilizou dados de mamografia do DATASUS/SISCAN referentes a residentes do Estado do Rio de Janeiro em 2025. A base foi preparada para classificação supervisionada, os modelos baseline foram comparados com versões otimizadas por Algoritmos Genéticos e, ao final, uma LLM foi integrada como camada de interpretação dos resultados estatísticos.

SISCAN Mamografia Base desbalanceada SVM Regressão Logística

Random Forest Algoritmo Genético LLMs

Identificação do Trabalho

Serão entregues uma versão em HTML e uma versão em PDF com o mesmo conteúdo. Recomenda-se, entretanto, que a avaliação do trabalho seja realizada preferencialmente pela versão em HTML, pois ela oferece melhor experiência de leitura, navegação e visualização das tabelas.

Autor	RM
Igor Hadson Leal Carletti	RM37
Paulo Eduardo Oliveira Moreira	RM37
Gustavo de Souza Lima	RM37

Vídeo no YouTube: <https://youtu.be/jxiiMiTQDt8>

Repositório: https://github.com/igorlealc/ia_tech_challenge_01_v2

Resumo Executivo

Base analisada

A base tratada preservou todos os registros do recorte original.

267.473

linhas após o tratamento

Classe positiva

O problema é fortemente desbalanceado, o que torna inadequada a avaliação baseada apenas em accuracy.

4,24%

aproximadamente na variável-alvo

Leitura operacional

As métricas principais são recall, F1, precision e balanced accuracy.

Recall

prioritário para reduzir falsos negativos

Resultados dos Modelos Otimizados

Modelo com AG	Melhor configuração
SVM Linear	C=0.01, class_weight=balanced, normalizer, max_iter=5000
Regressão Logística	C=0.01, class_weight=balanced, normalizer, max_iter=2000
Random Forest	n_estimators=100, max_depth=8, min_samples_leaf=10, class_w

Os valores foram extraídos das avaliações finais dos notebooks de tuning com Algoritmos Genéticos nas Partes 7, 8 e 9. A especificidade foi derivada da relação entre balanced accuracy e recall: especificidade = $2 * \text{balanced accuracy} - \text{recall}$.

Sensibilidade e Especificidade

Em saúde da mulher, especialmente em triagem para câncer de mama provável, a sensibilidade é prioritária porque está associada à redução de falsos negativos. Entretanto, a especificidade também é relevante, pois baixa especificidade aumenta falsos positivos, exames complementares, ansiedade e sobrecarga operacional.

SVM e Regressão Logística apresentaram os maiores valores de recall, mas essa decisão reduziu a especificidade para aproximadamente 0,4373 e 0,4330, respectivamente. Isso indica que esses modelos tendem a capturar mais casos positivos, porém também classificam mais casos negativos como positivos.

A Random Forest otimizada apresentou menor recall em comparação com SVM e Regressão Logística, mas preservou especificidade superior, aproximadamente 0,7758. Por esse motivo, ela representa o melhor compromisso entre sensibilidade clínica e viabilidade operacional.

Comparação com os Baselines

Modelo	Delta Accuracy	Delta Balanced Accuracy	Delta Precision	Delta Recall
SVM Linear	-0,2331	-0,0428	-0,0178	+0,0000
Regressão Logística	-0,2343	-0,0278	-0,0142	+0,0000
Random Forest	-0,0362	+0,0079	-0,0042	+0,0000

Integração com LLMs

A Parte 10 integrou uma LLM ao fluxo do projeto para transformar métricas agregadas e exemplos individuais em explicações textuais claras, cautelosas e auditáveis. A integração foi estruturada por meio de prompts de segurança, payloads sem identificação pessoal, validação automática das respostas e registro dos artefatos gerados.

A LLM não foi utilizada como classificador e não substituiu os modelos estatísticos. Sua função foi interpretar os resultados produzidos pelos modelos, comunicar incertezas, evitar

linguagem diagnóstica e reforçar que qualquer aplicação em saúde exige validação adicional e avaliação profissional.

Os artefatos da integração foram registrados em **resultados/parte_10_integracao_llms/**, incluindo prompts individuais e agregados, respostas geradas, validações em JSON, auditoria das interpretações e tabela de métricas encaminhada à LLM. Esse registro torna a etapa reprodutível e permite revisar o comportamento da camada interpretativa.

A abordagem adotada foi sensível ao gênero por reconhecer que o contexto clínico envolve saúde da mulher e exige comunicação cuidadosa, sem culpabilização, estigmatização ou inferências indevidas sobre pacientes. Os prompts orientam a LLM a explicar risco estatístico, comunicar incerteza, evitar diagnóstico, preservar privacidade e recomendar validação profissional.

A qualidade das respostas foi avaliada por critérios de segurança e consistência: ausência de diagnóstico definitivo, ausência de prescrição clínica, aderência às métricas fornecidas, linguagem cautelosa, preservação de anonimato e coerência entre explicação individual e interpretação agregada.

Análise de Equidade

A equidade foi considerada como requisito de avaliação, pois modelos aplicados a triagem em saúde podem apresentar desempenhos diferentes entre grupos demográficos. As variáveis disponíveis no fluxo, como idade, sexo informado, raça/cor e localização, permitem estruturar auditorias por subgrupos.

Nesta versão do trabalho, a análise quantitativa completa de desempenho por subgrupo ainda não foi consolidada em tabela final. Portanto, a conclusão não afirma equivalência de desempenho entre grupos. A recomendação técnica é calcular, antes de qualquer uso real, recall, especificidade, precision, F1, taxa de falsos positivos e taxa de falsos negativos por faixas etárias, raça/cor, município e demais recortes demográficos disponíveis.

Um ponto de atenção já identificado é que categorias como raça/cor ignorada ou sem informação não devem ser interpretadas como característica demográfica informativa. A ausência ou baixa qualidade de preenchimento pode refletir desigualdade de registro e precisa ser tratada como risco de viés.

No primeiro Tech Challenge, foi realizada uma tentativa de agrupamento para obtenção de features adicionais. Contudo, entre as informações pessoais disponíveis, a única que influenciou de maneira consistente a formação de agrupamentos foi a idade. Esse resultado reforça a necessidade de cautela na interpretação de variáveis demográficas e indica que a idade deve ser auditada com atenção em futuras análises de equidade.

Desafios e Soluções Implementadas

- **Desbalanceamento da classe positiva:** foram priorizadas métricas como recall, F1 e balanced accuracy, além do uso de `class_weight` e função de fitness orientada à classe positiva.
- **Risco de leakage:** colunas de laudo, resultado, BI-RADS, recomendações e achados finais foram isoladas para não compor as features de entrada dos modelos.
- **Custo computacional dos modelos:** foram utilizadas amostragens estratificadas, validação cruzada controlada e experimentos de Algoritmo Genético com populações e gerações definidas.
- **Interpretação de resultados em saúde:** a integração com LLMs foi limitada a uma camada explicativa, com prompts de segurança e auditoria das respostas.
- **Qualidade e rastreabilidade dos dados:** o fluxo preservou bases intermediárias, arquivos Parquet e artefatos de validação para permitir reexecução e revisão do processo.

Considerações Éticas

O projeto trata um problema sensível de saúde pública e, portanto, deve ser avaliado sob os princípios de privacidade, mitigação de vieses, transparência, supervisão humana e responsabilidade social.

- **Privacidade:** a etapa com LLMs utiliza payloads sem identificação pessoal e não deve enviar dados nominativos ou identificadores sensíveis a serviços externos.
- **Impacto social:** falsos negativos podem atrasar investigação clínica, enquanto falsos positivos podem gerar ansiedade, exames adicionais e pressão sobre o sistema de saúde.
- **Transparência:** métricas, limiares, matriz de confusão, prompts e respostas da LLM devem permanecer documentados para revisão técnica.
- **Supervisão humana:** nenhum resultado do modelo ou da LLM deve ser utilizado como diagnóstico ou decisão clínica automatizada.

Conclusão

O Algoritmo Genético cumpriu o objetivo do trabalho ao implementar seleção, cruzamento, mutação, elitismo, função de fitness e três experimentos por modelo. A fitness adotada, $0,7 * F1 + 0,3 * \text{recall}$, foi adequada ao contexto, pois direcionou a busca para a classe positiva, que é rara.

Na comparação final, SVM e Regressão Logística elevaram substancialmente o recall, indicando maior capacidade de capturar casos positivos. Entretanto, essa melhora foi acompanhada por queda em precision, F1, balanced accuracy e accuracy, o que sugere maior volume de falsos positivos.

A Random Forest otimizada apresentou o resultado mais equilibrado: aumentou o recall em relação ao baseline, melhorou levemente a balanced accuracy e manteve a menor perda de F1 entre os modelos avaliados. Portanto, considerando desempenho e viabilidade operacional, ela é a alternativa mais consistente entre os modelos otimizados.

A integração com LLMs complementou o trabalho ao oferecer uma camada formal de interpretação dos resultados, com mecanismos de segurança textual e auditoria. Essa etapa fortalece a comunicação dos achados, mas não altera a natureza estatística do projeto nem autoriza uso clínico sem validações adicionais.

Recomendação Final

O modelo deve ser tratado exclusivamente como apoio à triagem e nunca como diagnóstico clínico. Antes de qualquer uso real, é necessário validar o desempenho em dados futuros, revisar erros por subgrupos, calibrar limiares e submeter a interpretação a profissionais responsáveis.

- Utilizar a Random Forest otimizada como principal candidata para continuidade do estudo.
- Manter SVM e Regressão Logística como alternativas quando a prioridade for maximizar recall.
- Evitar conclusões baseadas apenas em accuracy, pois a classe positiva representa pequena fração da base.
- Registrar limiares, matriz de confusão e impacto operacional antes de qualquer aplicação fora do ambiente acadêmico.
- Utilizar a integração com LLMs apenas como camada explicativa, sempre com validação, auditoria e restrições contra interpretação diagnóstica.